

ANALISI DI DATI CLINICI

Corso: Scientific Visualization

A cura di: Christian Cioffi (28820A) e Federico Garegnani (41712A)



Indice

1. Presentazione del dataset
2. Data pre-processing
3. MOFA
4. Data classification
5. Data clustering
6. Interpretazione dei risultati

Dataset di partenza

Il lavoro svolto si basa sull'utilizzo di 7 dataset:

- un dataset contenente i dati demografici, clinici e patologici di 140 pazienti (identificati dall'attributo *case_id*) (questo dataset, d'ora in avanti, verrà chiamato «dataset clinico»),
- sei dataset (trasposti) rappresentanti viste omiche su 137 (di 140 dei) pazienti presenti nel primo dataset (ogni riga si riferisce ad uno specifico paziente).

Panoramica sul dataset dei pazienti

Categoria	Feature	Descrizione
Dati demografici	age	Età
Dati demografici	sex	Sesso
Dati demografici	race	Etnia
Dati demografici	participant_country	Paese d'origine
Abitudini	bmi	Indice di massa corporea
Abitudini	alcohol_consumption	Consumo di alcool
Abitudini	tobacco_smoking_history	Consumo di sigarette
Dati patologici	histology_diagnosis	Diagnosi istologica (PDAC = adenocarcinoma duttale pancreas)
Dati patologici	tumor_site	Localazione tumore
Dati patologici	tumor_size_cm	Dimensione tumore (cm)
Dati patologici	tumor_necrosis	Necrosi tumorale (se presente o meno)
Dati patologici	tumor_stage_pathological	Stadio patologico del tumore
Dati patologici	residual_tumor	Tumore residuo a seguito di intervento chirurgico (valutazione istologica)
Dati patologici	lymph_vascular_invasion	Invasione linfatico-vascolare (se presente o meno)
Dati patologici	perineural_invasion	Invasione perineurale (se presente o meno)
Dati patologici	pathologic_staging_regiol_lymph_nodes_pn	Linfonodi regionali positivi (valutazione istologica)
Dati patologici	pathologic_staging_primary_tumor_pt	Tumore primario (valutazione istologica)
Dati patologici	pathologic_staging_distant_metastasis_pm	Metastasi a distanza (valutazione istologica)
Dati patologici	clinical_staging_distant_metastasis_cm	Metastasi a distanza (valutazione clinica)
Dati conclusivi	follow_up_days	Giorni di follow-up (monitoraggio paziente)
Dati conclusivi	vital_status	Stato vitale
Dati conclusivi	is_this_patient_lost_to_follow_up	Non si hanno più notizie del paziente durante il follow-up
Dati conclusivi	cause_of_death	Causa del decesso

Panoramica sulle viste omiche (trasposte)

Vista Omica	Feature	Valori
circRNA	Le singole molecole di circular RNA (circRNA)	Livello di espressione dei vari circRNA nel paziente
miRNA	Le singole molecole di microRNA (miRNA)	Livello di espressione dei vari microRNA nel paziente
mRNA	I singoli geni	Livello di espressione dei vari geni nel paziente
phosphoproteome gene	I singoli geni	Livello di fosforilazione associato ai vari geni nel paziente
proteome gene	I singoli geni	Livello di abbondanza proteica dei vari geni nel paziente
SCNA gene	I singoli geni	Alterazione somatica del numero di copie dei vari geni nel paziente

DATA PRE-PROCESSING

Data Pre-processing


- Le viste omiche sono state inizialmente trasposte, dato che i pazienti erano disposti sulle colonne.
- Il dataset clinico e le varie viste sono state poi allineate, eliminando tre pazienti dal primo dataset.
- All'interno del dataset clinico sono state codificate le variabili categoriche. In particolare:
 - le variabili nominali sono state codificate tramite «**one-hot encoding**»,
 - le variabili binarie sono state codificate tramite **codifica binaria 0/1**,
 - le variabili ordinali sono state codificate **numericamente**, mantenendo l'ordine delle etichette.
- La colonna '*histology_diagnosis*' è stata eliminata in quanto poco informativa.

Data Pre-processing


Per quanto concerne le viste omiche è stato applicato un doppio filtraggio, andando prima ad eliminare prima le feature con una percentuale di NaN («**missing values**») al di sopra di una soglia prefissata (**25%**) e andando poi a rimuovere le feature a **varianza zero** (utile per MOFA). Anche per il dataset clinico è stata applicata la rimozione delle feature con una percentuale di NaN al di sopra di una certa soglia (**40%**).




Analisi missing values per vista




Analisi missing values per vista



Analisi dei valori mancanti per feature



Analisi dei valori mancanti per feature



Data Imputation (viste omiche)

- Ogni singola vista è andata incontro ad un procedimento di **standardizzazione**, in modo che ogni colonna avesse una distribuzione di valori con **media 0 e deviazione standard 1**.
- Questa operazione è di norma consigliata prima di fare imputazione con kNN dei dati mancanti, per evitare che variabili su larga scala possano influire troppo sul calcolo delle distanze tra i campioni considerati.
- Successivamente, l'imputazione è stata applicata, su ciascuna vista che presentava «missing values», tramite la tecnica di **kNN-Imputation**.
- Infine una **ri-standardizzazione** (opzionale) è stata applicata in modo da avere dati perfettamente standardizzati per l'uso di MOFA.

kNN Imputation

Per ogni vista:

- vengono scelti in modo casuale i «test holes» (valori presenti, ma simulati come NaN, usati successivamente per il calcolo dell'RMSE), corrispondenti al **5%** dei valori presenti;
- viene eseguita l'imputazione kNN con vari k (da 3 a 19), calcolando l'RMSE ogni volta;
- viene scelto il k con l'**RMSE (Root Mean Square Error)** migliore (più basso);
- viene effettuata l'imputazione finale col k migliore.



Data Imputation (dataset clinico)

- Anche sul dataset clinico è stata applicata la **standardizzazione**, ma solo alle **feature non binarie** (le feature binarie non presentano larghi scale).
- Anche qui è stato usato **kNN Imputation**, seguendo la stessa procedura applicata alle viste omiche.
- Al contrario di quanto fatto con queste ultime, è stata applicata una **de-standardizzazione** allo scopo di ottenere i dati originali (più i dati mancanti de-standardizzati).
- A seguito di ciò, è stato effettuato anche un arrotondamento di valori (all'intero più vicino) che in realtà sarebbero dovuti essere discreti, ma che a causa dell'imputazione kNN hanno assunto valori continui.



MOFA



Presentazione MOFA

- Metodo non supervisionato per l'integrazione di dati multi-omici
- Riduzione della dimensionalità dei dati
- Identifica le principali fonti di variazione nei dati e le astrae in termini di fattori latenti



Presentazione MOFA

Sia

- N numero di campioni (pazienti)
- m numero di viste del dataset
- D_m numero di feature della vista m
- Y_m matrice dei dati della vista m ($Y_m \in \mathbb{R}^{N \times D_m}$)

Si ha
$$Y_m = Z \cdot W_m^T + \epsilon_m$$

Dove

- $Z \in \mathbb{R}^{N \times k}$ matrice dei fattori
- $W_m \in \mathbb{R}^{D_m \times k}$ matrice dei pesi
- $\epsilon_m \in \mathbb{R}^{N \times D_m}$ matrice del rumore



Fattori latenti

Matrice Z dei fattori latenti


- Ciascuna riga fa riferimento a un paziente
- Le colonne rappresentano il valore numerico del fattore per il relativo paziente

case_id	Factor1	Factor2	Factor3	Factor4	Factor5	Factor6	Factor7	Factor8	Factor9	Factor10	Factor11	Factor12	Factor13
C3L-00017	3,772759	-0,02418	-0,03968	1,37511	-0,55172	-0,17681	0,165779	-0,1129	1,244698	-0,19767	-0,65969	0,129649	-0,20065
C3L-00102	1,362362	-0,28371	0,847602	3,748061	-1,12464	0,037608	0,609494	-0,07204	-0,81296	-0,02806	0,364193	0,017682	0,086342
C3L-00189	2,768533	-1,33681	0,614068	-0,47636	1,154339	0,115143	0,24877	-0,08408	-0,41831	-0,13563	-0,08027	-0,00615	-0,13808
C3L-00277	1,526149	1,867423	1,530237	1,292304	-0,3624	-0,07297	-0,12494	-0,22657	0,509663	-0,44652	-0,40479	-0,06045	-0,1092
C3L-00401	3,035923	0,111856	0,122542	0,457961	-0,34156	-0,06962	0,115786	-0,08763	0,447297	-0,05259	-0,03377	-0,00203	-0,15311
C3L-00589	1,920031	0,387823	0,577538	2,442132	-0,83588	-0,03693	0,119573	-0,17302	-0,60504	-0,31653	-0,56661	-0,03668	0,011672




Varianza spiegata R^2

- Indica la percentuale di informazione contenuta nei dati originali che il modello è riuscito a comprendere e riassumere
- Valori più alti sono migliori
- Più alto è il valore, maggiore è la fiducia che i fattori latenti rappresentino reali processi biologici e non semplici fluttuazioni casuali dei dati



Heatmap dei pesi

- Indica quali feature guidano quel fattore
- Il valore assoluto di un peso indica quanto quella feature contribuisce alla variazione spiegata di quel fattore
- Pesi positivi indicano che la feature co-varia positivamente con il fattore
- Pesi negativi significano che la feature ha una correlazione inversa rispetto al fattore



Heatmap dei pesi per la vista «mRNA»

Significato dei fattori latenti

Si procede nel seguente modo:


1. Analisi delle caratteristiche omiche determinanti (driver) per ogni fattore
2. Ricerca del significato clinico dei fattori
3. Unione dei dati

Analisi dei driver omici per fattore

Per ogni fattore latente:

- All'interno di ogni vista, vengono selezionate le feature con i pesi maggiori (top 10)
- Divide i valori numerici associati al fattore in due gruppi: «alto» e «basso» sulla base del valore della mediana
- Esegue il test di Wilcoxon (Mann-Whitney U) sui due gruppi (alto e basso), il quale restituisce un p-value

Si cerca di capire se i pazienti che hanno un'altra espressione di un gene hanno anche un valore del fattore significativamente diverso rispetto a chi ha una bassa espressione del gene.



Indica con quanta sicurezza siamo in grado di affermare che la distribuzione dei *factor scores* è significativamente diversa tra i pazienti con «alta» e «bassa» espressione del gene

Analisi dei driver omici per fattore

	Factor	View	Feature	Weight	Wilcoxon_p-value	p-adj
18	Factor1	miRNA	hsa-miR-222-3p	-0,23083	7,68E-05	0,059914
14	Factor1	miRNA	hsa-miR-221-3p	-0,25342	0,01323	0,495081
45	Factor1	proteome	TCEAL3	0,379767	0,01075	0,495081
49	Factor1	proteome	CGNL1	0,37443	0,013071	0,495081
15	Factor1	miRNA	hsa-miR-99a-3p	0,244521	0,016202	0,52656
34	Factor1	phosphoproteome	DCLK1	0,37151	0,034353	0,576221
29	Factor1	mRNA	SHE	0,44697	0,042377	0,621407

Analisi dei driver omici per fattore

In totale vengono eseguiti
 $13 \text{ fattori} \cdot 6 \text{ viste} \cdot 10 \text{ geni} = 910 \text{ test}$



Problema legato all'esecuzione di test multipli



p-value va corretto per tener conto
dell'alto numero di test



Metodo di Benjamini-Hochberg
All'aumentare del numero di test, il valore di p-value va alzato



$p\text{-adj} = \text{FDR (False Discovery Rate)}$

Significato clinico per i fattori latenti

- Vengono considerate le variabili categoriche della vista clinica
- Il valore di ciascun fattore viene discretizzato in «alto» e «basso» secondo il valore mediano
- Esegue il test χ^2 tra fattori discretizzati e ciascuna variabile categorica
- Applica correzione al p-value per test multipli

	Factor	Clinical_Variable	Chi2_Stat	p-value	n_patients	p-adj
15	Factor1	alcohol_consumption	31,06323	2,97E-06	135	0,000773
3	Factor1	participant_country	43,81563	7,83E-06	137	0,001018
73	Factor4	tumor_stage_pathological	15,58351	0,008139	131	0,705421
17	Factor1	vital_status	4,742749	0,029422	133	0,804292
36	Factor2	tobacco_smoking_history	10,8257	0,054947	135	0,804292
43	Factor3	participant_country	20,82284	0,035254	137	0,804292

Unione risultati dei test

- Per ogni fattore raggruppa i driver omici significativi con p-adj minore di una soglia scelta
- Analogo per variabili cliniche
- Identifica, dove presenti, le caratteristiche di maggior rilevanza per quel fattore

Fattore	Driver Molecolari (Top 5)	Viste Coinvolte	Associazioni Cliniche	Sintesi Interpretativa
0 Factor1	hsa-miR-222-3p	miRNA	alcohol_consumption, participant_country	Asse biologico guidato da hsa-miR-222-3p con impatto su alcohol_consumption, participant_country
1 Factor10	hsa-miR-629-5p, hsa-miR-346	miRNA	Nessuna associazione clinica	Processo biologico coinvolgente hsa-miR-629-5p, hsa-miR-346 (clinicamente silente)
2 Factor11	PPIL2	mRNA	Nessuna associazione clinica	Processo biologico coinvolgente PPIL2 (clinicamente silente)
3 Factor12	Nessun driver forte		Nessuna associazione clinica	Indefinito
7 Factor4	hsa-miR-200a-3p	miRNA	Nessuna associazione clinica	Processo biologico coinvolgente hsa-miR-200a-3p (clinicamente silente)



DATA CLASSIFICATION

Data Classification

A seguito di MOFA, si è deciso di applicare varie tecniche di **classificazione** sui campioni/pazienti considerando come feature i **fattori latenti** prodotti da **MOFA** e come label da predire prima la colonna «***vital_status***» (presa dal dataset clinico) e poi «***tumor_stage_numerical***» (prese entrambe dal dataset clinico). Queste due colonne sono le codifiche numeriche di due colonne categoriche, rispettivamente «*vital_status*» e «*tumor_stage_pathological*».



Data Classification (*vital_status*)

- Suddivisione del dataset (fattori MOFA + colonna «*vital_status*») in **training set** (80%) e **test set** (20%);
- Bilanciamento del training set ottenuto tramite **oversampling** della classe minoritaria (questo implica la creazione di duplicati);
- Applicazione di vari modelli di ML di classificazione (sia binaria che multiclasse) al dataset, ovvero **kNN**, **Logistic Regression** e **Random Forest**;
- Calcolo di **permutation importance**, **coefficient importance** e **feature importance** a seguito del training dei modelli;
- Calcolo di metriche di valutazione sul test set: **(AU)ROC**, **(AU)PRC**, **accuracy**, **F1**, **precision** e **recall**.



Configurazione dei modelli di classificazione

- Il **kNN** è stato usato impostando il numero di vicini **k** a **5**. Per questo modello è stato calcolato il **permutation importance**, basato sull'F1 score.
- Il **Logistic Regression** non ha avuto bisogno di particolari configurazioni e né tantomeno è stato possibile calcolare forme particolari di feature importance, limitandoci al basico calcolo del **coefficient importance** (ovvero il coefficiente delle varie feature)
- Il **Random Forest** che abbiamo usato si compone di **500** decision tree. E' stata poi considerata la **feature importance**, basata sul gini score, delle varie feature.




Permutation importance

Con **permutation importance** si intende quanto una metrica di base (**F1-Score** nel nostro caso) cambia permutando i valori di una feature tra tutti i campioni. Valori positivi indicano un peggioramento dello score, il che significa che la feature è **importante** per il modello (più alto il valore, più importante sarà). Valori prossimi allo 0 (o 0 stesso) indicano una feature **inutile**, dato che la permutazione dei valori non porta a cambiamenti significativi nella metrica. Valori negativi indicano una feature **dannosa**, la cui permutazione dei valori porta ad un miglioramento dello score.



Permutation Importance (kNN)



Coefficient Importance


Con **coefficient importance** si intende l'importanza predittiva che una feature imprime sulla predizione finale del modello. Nel caso binario, dove si considera una classe positiva e una negativa:

- Con **forza predittiva** si intende il valore assoluto del coefficiente di una feature (più è alto, più quella feature impatterà sulle predizione finale).
- Con **direzione predittiva** si intende il segno del coefficiente, ovvero se la feature influisce positivamente o negativamente la predizione della classe positiva.

Il coefficient importance si può calcolare in tutti quei modelli che si basano sull'uso di un'equazione matematica (le cui variabili sono le feature) per fare le predizione, come ad esempio Linear Regression e **Logistic Regression**.



Coefficient Importance (Logistic Regression)




Feature Importance

Nel Random Forest con «**feature importance**» (o «**gini importance**») si intende quanto una feature contribuisce a rendere i nodi degli alberi di decisione puri (dal punto di vista del gini score). Il **gini score** di un nodo di un albero di decisione rappresenta l'impurità del nodo. Un nodo è puro (gini score pari a 0) se il nodo è stato applicato, in fase di training, solo a campioni della medesima classe. La riduzione di gini score (tra il nodo della feature e i nodi figli) si calcola per ciascun albero della foresta e poi si fa una media (pesata o meno sul numero di «*training samples*» del nodo in ciascun albero) tra tutti gli alberi.



Feature Importance (Random Forest)





Curva ROC

La curva **ROC** è una curva con **FPR** sull'asse X e **TPR** (o Recall) sull'asse Y e che rappresenta la variazione della coppia (FPR, TPR) al variare della soglia di decisione del modello di classificazione. L'area sotto la curva (**AUROC**) rappresenta la probabilità (massima pari a 1) che un campione con true label positiva riceva un punteggio di decisione alto rispetto ad un campione con true label negativa. Il **random classifier**, la cui curva ROC è la bisettrice del primo e terzo quadrante, ha infatti un'AUROC pari a 0.5.



Curva PRC

La curva **PRC** è una curva con TPR (o **Recall**) sull'asse X e **Precision** sull'asse Y e rappresenta la variazione della coppia (Recall, Precision) al variare della soglia di decisione del modello di classificazione. L'area sotto la curva prende il nome di **AUPRC** e rappresenta la capacità di un modello di mantenere sia un'alta precisione che un'alta recall. Il **random classifier**, la cui curva coincide con un segmento parallelo all'asse X, ha un AUPRC pari al rapporto tra il totale dei campioni positivi e il totale dei campioni. La PRC è più attendibile in caso di presenza di **classi sbilanciate** (come nel nostro caso).



Curve ROC e PRC (kNN)



Curve ROC e PRC (Logistic Regression)



Curve ROC e PRC (Random Forest)



Valutazione del modello migliore


Al fine di valutare il modello migliore sono state considerate le seguenti metriche (valutate sul **test set**):

- **Accuracy:** $(TP+TN)/TOTALE$
- **Precision:** $TP/(TP+FP)$
- **Recall:** $TP/(TP+FN)$
- **F1-Score:** $2*(Precision*Recall)/(Precision+Recall)$
- **AUROC**
- **AUPRC**


Precision, Recall e F1-Score sono state calcolate in modo **pesato**, ovvero la metrica è stata calcolata per ciascuna classe e si è fatta poi una media tra tutte le classi pesata sul numero di campioni di ciascuna classe.

La metrica decisiva per scegliere il modello migliore è stata l'**AUPRC**, dato che è quella più adatta quando si è in presenza di dataset sbilanciati. Il modello migliore è risultato essere il **Logistic Regression**.

Metriche di valutazione



Contributo delle viste alle predizioni del modello migliore



Data Classification (tumor_stage_numerical)

Per quanto riguarda la classificazione effettuata considerando la feature «tumor_stage_numerical» come label da predire, le operazioni sono state pressochè simili:

- Suddivisione del dataset (fattori MOFA + colonna «*tumor_stage_numerical*») in **training set** (80%) e **test set** (20%);
- Bilanciamento del training set ottenuto tramite **oversampling** delle classi minoritarie;
- Applicazione di vari modelli di ML di classificazione al dataset, ovvero **kNN**, **Logistic Regression** e **Random Forest**;
- Calcolo di **permutation importance**, **coefficient importance** e **feature importance** a seguito del training dei modelli;
- Calcolo di metriche di valutazione sul test set: **(AU)ROC**, **(AU)PRC**, **accuracy**, **F1**, **precision** e **recall**.




Data classification binario vs multiclass

Ci sono delle **differenze** tra la classificazione multiclasse effettuata su «tumor_stage_numerical» e la classificazione binaria fatta su «vital_status»:


- Il bilanciamento riguarda tutte le classi che non sono la classe maggioritaria;
- Siccome il Logistic Regression di default usa l'approccio **Softmax** per gestire il caso multiclasse, i coefficienti delle feature sono diversi per ciascuna classe, pertanto il coefficient importance di ciascuna feature è calcolato come **media dei valori assoluti** dei coefficienti di tutte le classi;
- Le curve ROC e PRC sono state calcolate su ciascuna classe usando un approccio OvR (**One vs Rest**), considerando k casi binari (con k il numero di classi a disposizione);
- E' stata definita poi una curva **media (pesata)** e la media delle AUROC e AUPRC delle singole curve è stata pesata sulla base della cardinalità delle varie classi.




Permutation Importance (kNN)





Coefficient Importance (Logistic Regression)





Feature Importance (Random Forest)





Curve ROC e PRC (kNN)



Curve ROC e PRC (Logistic Regression)




Curve ROC e PRC (Random Forest)




Valutazione del modello migliore

Al fine di valutare il modello migliore sono state considerate le medesime metriche considerato per il caso di classificazione binaria. La metrica decisiva per scegliere il modello migliore è stata l'**AUPRC**, dato che è quella più adatta quando si è in presenza di dataset sbilanciati. Il modello migliore è risultato essere il **Logistic Regression**.

Metriche di valutazione



Contributo delle viste alle predizioni del modello migliore



DATA CLUSTERING



Data Clustering

- A partire dai fattori latenti di MOFA abbiamo deciso di applicare quattro tecniche di clustering al fine di visualizzare quali cluster potessero definirsi tra i vari campioni.
- Le quattro tecniche di clustering usate sono **K-Means, HDBSCAN, Spectral Clustering e Gaussian Mixture Model (GMM)**.
- Per ogni tecnica sono stati visualizzati:
 - i risultati del clustering in 2D tramite l'uso di **T-SNE**;
 - la variazione di metriche come il **Silhouette Score** (e il **BIC** nel caso del GMM) al variare del k (numero di cluster) considerato (eccetto che nel caso di HDBSCAN, dove il k ottimale è definito in modo automatico)
 - Due **tabelle di contingenza** (una per «*vital_status*» e una per «*tumor_stage_numerical*») che mostrano come le true labels si distribuiscono rispetto ai cluster predetti.



Metriche di valutazione


- **Silhouette Score:** valore che misura la coesione intra-cluster (basato sulle distanze medie dei punti in un medesimo cluster) e la separazione intra-cluster (basato sulle distanze medie tra punti di cluster differenti). Più alto è, meglio è (indica cluster ben separati tra loro, ma coesi internamente).
- **BIC (Bayesian Information Criterion):** indice che misura quanto un modello sia accurato e allo stesso semplice (bilanciamento tra le due cose). Adatto per GMM (rispetto a Silhouette Score). Più basso è, meglio è (clustering migliore).
- Per selezionare la tecnica di clustering migliore si è deciso di usare il silhouette score, considerando, nel caso del Gaussian Mixture Model, il silhouette score del modello con il BIC minimo. Il **modello migliore** è risultato essere l'**HDBSCAN**.

Configurazione delle tecniche


Tecnica di Cluster	k	Configurazione
K-Means	2-20	-
HDBSCAN	Automatico	min_cluster_size=2, metric='euclidean'
Spectral Clustering	2-20	affinity= 'nearest_neighbors'
Gaussian Mixture Model	2-20	covariance_type='full'

Nota: sono stati considerati solo valori dispari per k


K-Means




K-Means




K-Means




K-Means




HDBSCAN




HDBSCAN




HDBSCAN




Spectral Clustering




Spectral Clustering




Spectral Clustering




Spectral Clustering




Gaussian Mixture Model




Gaussian Mixture Model



Gaussian Mixture Model



Gaussian Mixture Model



INTERPRETAZIONE DEI RISULTATI



Convalida dei cluster

- Si valuta il clustering eseguito da HDBSCAN
- Verifica se le differenze tra cluster sono significative
- Eseguiti due diversi test, che restituiscono entrambi un p-value

TIPOLOGIA VARIABILE	TEST EFFETTUATO
Numerica	Kruskal-Willis
Categorica	χ^2

Valore p-value
per una feature

La feature ha un grande peso nella distinzione in gruppi (cluster)

La feature è poco significativa nella destinzione dei cluster

	Variable	Test	Statistic	p-value	Significant
0	Factor1	Kruskal-Wallis	21,83172	7,07E-05	TRUE
1	Factor2	Kruskal-Wallis	20,26621	0,000149	TRUE
6	Factor7	Kruskal-Wallis	18,18404	0,000403	TRUE
29	clinical_staging_distant_meta stasis_cm	Chi-Square	17,87347	0,006556	TRUE
4	Factor5	Kruskal-Wallis	10,91621	0,012188	TRUE



Distribuzione feature categoriche per cluster

- Determina la caratteristica dei pazienti per gruppo
- Cerca la moda per ogni cluster e variabile categorica

LEGENDA

BOAA: Black or African American

RNRT : R0: No residual tumor


ACETO: Alcohol consumption equal to or less than 2 drinks per day for men and 1 drink or less per day for women

LND: Lifelong non-drinker

LNSLT: Lifelong non-smoker: Less than 100 cigarettes smoked in lifetime


CSIDA: Current smoker: Includes daily and non-daily smokers

PC: pancreatic carcinoma




Profili feature numeriche e binarie per cluster

- Calcola media (standardizzata) per feature all'interno di ogni cluster
- Mostra quanto ogni cluster si discosta dalla media generale del cluster



Profilazione cluster sulla base di fattori MOFA

- Si vogliono individuare i motori molecolari che definiscono ciascun cluster
- Calcola media di ciascun fattore all'interno di ciascun cluster
- Valori standardizzati con Z-score



Top 3 feature per fattore e vista

- Individua le molecole principali associate a ciascun fattore
- Estratte le top 3 caratteristiche per 3 fattori

